

MGL 25/26 - Q2 Primavera - Projecte de laboratori

Universitat Politècnica de Catalunya

Grau en Intel·ligència Artificial

Aspect-Based Sentiment Analysis

amb Large Language Models

Extracció d'aspectes i polaritats en reviews de restaurants mitjançant prompting, generació de dades sintètiques i fine-tuning.

Autors:
Pau Hidalgo Pujol
Jaume Mora i Ladària

Data:
28 de maig del 2026

Índex

1 Introducció **3**

2 Disseny experimental **3**
2.1 Models, dades i mètriques . . . 3
2.2 Prompts . . . 4
2.3 Decoding i quantització . . . 4

3 Zero-shot prompting **4**
3.1 Repetició . . . 5
3.2 Resultats i anàlisi . . . 5
3.3 Conclusions . . . 7

4 Few shot prompting **7**
4.1 Prompt . . . 7
4.2 Selecció d'exemples . . . 7
4.3 Resultats i anàlisi . . . 8
4.4 Conclusions . . . 9

5 Data agumentation **10**
5.1 Variants de dades sintètiques . . . 10
5.2 Control manual de qualitat . . . 10

6 Fine-tuning **11**
6.1 Datasets . . . 11
6.2 LORA attention vs LORA all . . . 11
6.3 Resultats . . . 11
6.4 Conclusions . . . 13

7 Experiments addicionals **13**
7.1 Ensembles . . . 13
7.2 Future work . . . 13

8 Conclusions generals **14**

A Prompts utilitzats **15**
A.1 Prompt base (*my_prompt*) . . . 15
A.2 Prompt de repetició (*repeat_review*) . . . 15
A.3 Prompt Chain-of-Thought (*cot*) . . . 16
A.4 Prompt amb definicions (*definitions*) . . . 17
A.5 Prompt amb regles de confusió (*confusion_guard*) . . . 18
A.6 Anàlisi d'errors . . . 20
A.7 Material addicional d'experiments . . . 21

1 Introducció

Aquest treball descriu els experiments realitzats en el context de *Aspect Based Sentiment Analyisis*.

El resum de resultats principals es mostra a la figura 1, que recull el paisatge general de les execucions individuals i destaca el millor resultat de cada família experimental.

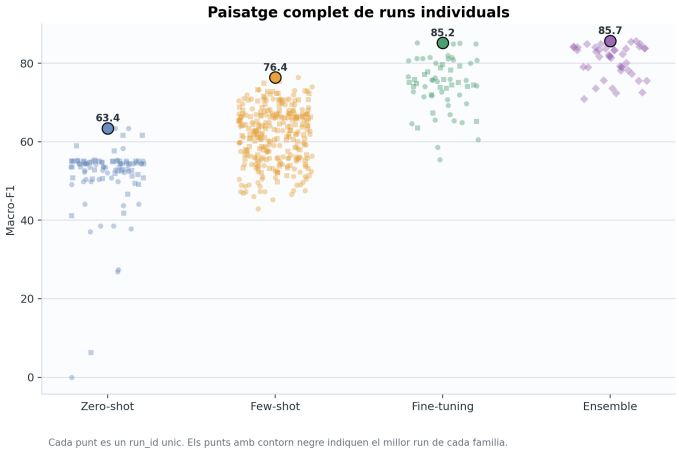


Figura 1: Cada punt correspon a un `run_id` unic; els punts ressaltats indiquen el millor resultat de cada familia experimental.

2 Disseny experimental

2.1 Models, dades i mètriques

Els models grans de llenguatge (LLM) utilitzats són LLama3.2 3B, i Qwen 2.5 3B. S'analitzen tècniques de zero-shot, few-shot, finetuning, data augmentation i ensembles.

Els experiments realitzats amb *greedy decoding* (temperatura 0) no inclouen replicació amb seeds. Alguns dels experiments que analitzen el comportament dels models amb altres paràmetres de temperatura i top-p inclouen replicacions amb 3 seeds. Tot i això, la majoria de resultats corresponen a una sola execució degut a límits de GPU i a haver prioritzat una exploració més àmplia d econfiguracions.

La sortida dels models avaluada és un JSON amb els diferents aspectes i polaritats. La mètrica principal utilitzada al llarg del document és el macro_f1 (en *devel*). Comentar una discrepància amb la implementació proporcionada: el codi original no tenia en compte els exemples del dataset on el "gold" és buit, i els comptabilitzava en tots els casos com a prediccions errònies. Aquest error ha estat solucionat.

També s'ha modificat el *finetune* per tal de maskejar correctament el prompt durant l'entrenament, i així evitar calcular la loss en les dades del prompt (ja que realment no és el que volem entrenar

del model).

Les mètriques secundàries avaluades són *micro_f1*, el percentatge de JSON vàlids, el percentatge de prediccions buides i el nombre d'errors. Aquestes només es reportaran quan siguin estrictament rellevants, però permeten entendre millor el comportament dels models.
S'ha provat quantització 4bit i els seus efectes sobre els models base.

2.2 Prompts

Els prompts utilitzats són:

- **Prompt base** El prompt base, anomenat *my_prompt* al cod, consisteix en un prompt relativament simple. El system prompt indica a l'LLM que és un sistema d'*Aspect-Based Sentiment Analysis*, juntament amb les instruccions generals, els aspectes i polaritats permesos i una menció específica a evitar incloure aspectes que no es mencionen explícitament.
- **Chain-Of-Thought Prompt** Prompt en el qual s'indica al model que raoni pas per pas abans de respondre [1], permetent-lo "pensar" Té l'inconvenient de generar més tokens, fet que incrementa el temps d'inferència.
- **Definitions** Prompt amb definicions més explícites de cada aspecte i polaritat, per evitar confusions entre categories properes.
- **Confusion guard**: prompt pensat per evitar errors freqüents, com ara confondre *food_quality* amb *restaurant_general*.

Aquests *prompts* s'han escollit per tal de ser una mostra representativa de diferents estils d'introduir instruccions als models de llenguatge. Altres proves, no incloses en el report, consistien en provar format XML o utilitzar castellà enlloc d'anglès, sense resultats concloents.

2.3 Decoding i quantització

Els paràmetres principals de decoding són la temperatura i el *top-p*. La majoria d'experiments es van executar amb temperatura 0, és a dir, *greedy decoding*. S'han provat (amb diverses combinacions) valors de temperatura baixos, com 0.1, 0.2, 0.3 (i algun cas de 0.5), combinant amb valors alts de *top-p*. No s'han provat valors de temperatura propers o majors a 1, ja que la tasca requereix més precisió que creativitat (ni valors baixos de *top-p*. Per a futurs experiments, seria interessant incloure també altres paràmetres com *min-p* o tècniques com *beam-search*.
També s'han provat models quantitzats a 4 bits, amb la llibreria *Bitsandbytes*. Aquesta quantització permet reduir els recursos necessaris (fet que ens va permetre dur a terme més experiments, executant models en paral·lel en una mateixa GPU, per exemple), però pot comportar degradació o canvis en el comportament dels models. En fine-tuning, aquesta quantització significa utilitzar QLoRA [3].

3 Zero-shot prompting

Aquests primers experiments intenten determinar quins resultats obtenen els models sense exemples ni entrenament, i analitzar on fallen per poder realitzar les intervencions més adequades. A més, s'analitzen alguns paràmetres de decoding i els efectes de quantització.

Es van provar els dos models, diferents prompts, diferents valors de temperatura i *top-p* i versions amb i sense quantització.

3.1 Repetició

També es va provar un prompt basat en la idea de *prompt repetition*. Aquesta tècnica consisteix a demanar al model que, abans de generar la predicció, rellegeixi i repeteixi internament l'input (només s'utilitze de manera interna i no s'inclou a la sortida final). Això pot millorar l'atenció del model sobre el text d'entrada i reduir errors derivats d'una lectura incompleta [4].

3.2 Resultats i anàlisi

El millor resultat zero-shot és 63.44, obtingut amb Llama, prompt *CoT*, sense quantització i *greedy decoding*

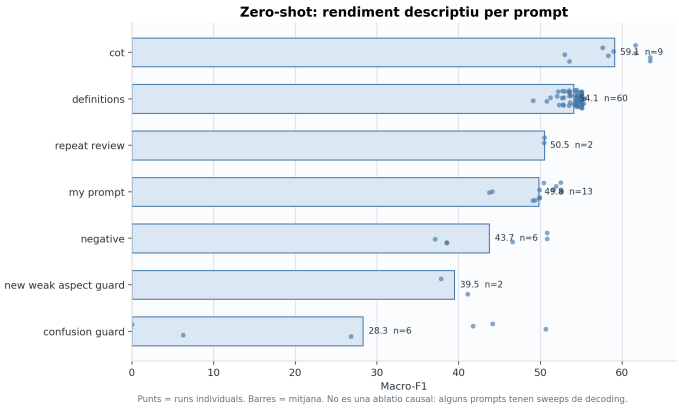


Figura 2: Rendiment zero-shot per prompt. Aquesta figura es descriptiva: el prompt `definitions` inclou un sweep de decoding i, per tant, les conclusions causals s'han de basar en les comparacions aparellades.

Prompt	Runs	Mitjana	Desv	Millor
cot	9	59.066	3.902	63.438
definitions	60	54.075	1.235	55.328
repeat_review	2	50.484	0.036	50.510
my_prompt	13	49.810	2.889	52.561
negative	6	43.732	6.431	50.819
confusion_guard	6	28.269	21.075	50.650

Taula 1: Resultats zero-shot per prompt. Taula descriptiva, no causal, perque alguns prompts tambe inclouen sweeps de decoding.

El *Chain-Of-Thought* obté els millors resultats en aquesta categoria, tot i que s'ha de pagar un cost: les seves execucions requerien límits de generació de tokens més elevats i el temps d'inferència es veia augmentat. Tot i això, mostra el potencial d'aquestes tècniques i el *test-time computing*.

Fer que el model raoni abans de respondre ajuda a identificar millor els aspectes específics.

El prompt amb definicions (amb 58 execucions, ja que es va analitzar amb diferents paràmetres de decoding i 3 seeds) és relativament estable. No arriba al millor resultat, però obté resultats bastant bons: amb Qwen, greedy decoding i sense quantitzacó, la macro-F1 és 55.04. Llama amb la mateixa configuració obté 54.44.

El prompt de repetició, en canvi, no mostra una millora clara en zero-shot. Tot i que la idea de forçar una relectura interna del text podia ajudar a reduir errors de lectura incompleta, en aquesta configuració els resultats queden molt a prop del prompt base. Per tant, sembla que sense exemples al context aquesta instrucció per si sola no és suficient per canviar gaire el comportament del model.

Els prompts pensat per evita rerrors concrets no milloren. *Confusion guard* té una mitjana molt baixa, i una desviació molt alta, fet que indica que instruccions negatives massa específiques provoquen que el model es torni massa conservador. Per exemple, Llama 3.2 amb aquest promt prediu buit el gairebé el 50% dels casos.

La taula 2 recull les comparacions aparellades que permeten fer afirmacions causals controlant la resta de variables:

Comparacio	Parelles	Base	Variant	Delta	Desv. delta
Qwen vs Llama	46	49.842	52.290	2.447	4.514
CoT vs my_prompt	8	49.994	59.173	9.179	2.127
Definitions vs my_prompt	6	49.682	53.212	3.529	1.291
Confusion guard vs my_prompt	4	51.226	20.929	-30.296	22.348
4bit vs no quant.	10	50.383	42.739	-7.645	15.397

Taula 2: Comparacions zero-shot aparellades, controlant la resta de variables disponibles.

Qwen té una mitjana lleugerament superior a LLama (en part degut als experiments de *confusion guard*, on el Qwen no obté resultats tan dolents com LLama) però el millor resultat individual és de Llama.

Pel que fa a la quantització, els resultats zero-shot mostren com afecta al rendiment del model. Les execucions sense quantització tenen una mitjana de 53.542, mentre que les 4bit tenen una mitjana de 43.698.
Per controlar els diferents paràmetres de decoding, es van realitzar diverses runs amb el prompt de *definitions.*

Temp.	Top-p	Parelles	Greedy base	Variant	Delta
0.0	-	8	54.737	54.737	0.000
0.2	0.5	8	54.737	54.451	-0.287
0.2	0.9	8	54.737	53.891	-0.847
0.2	1.0	8	54.737	53.542	-1.195
0.5	0.5	8	54.737	54.740	0.002
0.5	0.9	8	54.737	53.685	-1.052
0.5	1.0	8	54.737	53.226	-1.511

Taula 3: Sweep de decoding amb el prompt definitions, controlant model i seed. La base es temperatura 0 i top-p 1.0.

Quan es controla per model, observem que augmentar la temperatura no millora el resultat en zero-shot. Per tant, en aquesta tasca de sortida estructurada, el decoding determinista sembla proporcionar els millors resultats, almenys amb *zero-shot*.

3.3 Conclusions

El zero-shot és útil com a baseline, però els models tenen encara molt marge de millora. Els models solen confondre categories properes, i tenen dificultats per predir categories com location o els preus específics d'elements. Aquesta diferència entre categories és important i s'adreçarà en les properes seccions, especialment a l'hora de generar dades sintètiques.

El prompt importa i afecta bastant al model, però sembla tenir un sostre, i fins i tot utilitzant tècniques avançades els models no son capaços d'arribar a un 70 de F1.

4 Few shot prompting

Els experiments de *few-shot* segueixen la mateixa idea que els de *zero-shot*, però afegint exemples anotats abans de la ressenya que es vol predir. Per tant, el model no només rep les instruccions del prompt, sinó que també veu exemples del train. Així, combinant les execucions del Boada i les addicionals, es van analitzar diferents models, prompts, shots i altres hiperparàmetres.

4.1 Prompt

Els prompts utilitzats són idèntics als de zero shot, afegint una frase indicant al model que se li proporcionaran exemples i que es fixi en l'estil i estructura.

4.2 Selecció d'exemples

La diferència entre *zero-shot* i *few-shot*, deixant de banda les lleugeres modificacions del prompt, és que en el segon introduïm una selecció d'exemples per tal de millorar el rendiment del model.

Escollir aquests exemples, per tant, és vital pel bon funcionament d'aquesta tècnica. S'han implementat i avaluat 4 tècniques diferents:

- First: Selecciona els primers N exemples del dataset.

- Random: Escull aleatòriament N exemples
- Diverse: Intenta escollir els exemples assegurant-se que no se solapin, intentant cobrir el màxim nombre de combinacions aspecte - sentiment possibles. Per tant, acaba prioritzant exemples amb molts sentiments, però diferents entre ells.
- Coverage Rank: similar a diverse, però intenta prioritzar els aspectes més fluixos. Aquests són: "location", "food_style_options", "drinks_quality", "food_prices" i "restaurant_prices".

4.3 Resultats i anàlisi

Els resultats de few-shot milloren clarament els de zero-shot. El millor resultat zero-shot era de 63.44 de macro-F1, mentre que la millor configuracions few-shot arriba fins a 76.36 i totes elles superen el 70. Això mostra que afegir exemples al context ajuda molt al model, especialment en una tasca on el format de sortida és molt concret.

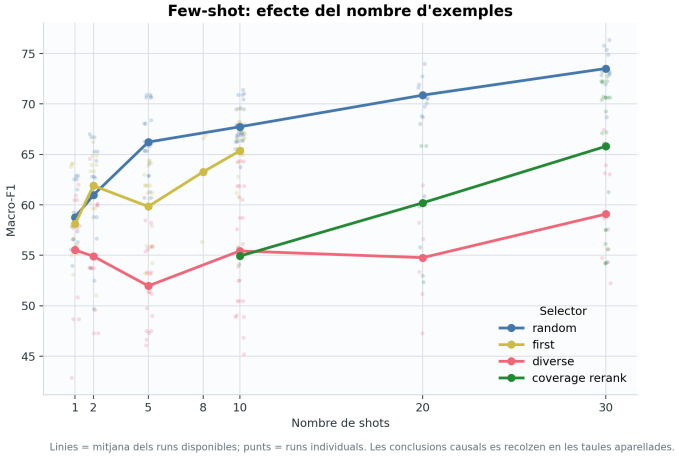


Figura 3: Efecte del nombre de shots i de l'estrategia de seleccio en few-shot. Les linies son mitjanes dels runs disponibles i els punts mostren execucions individuals.

Model	Prompt	Shots	Quant.	Estratègia	Macro-F1
Llama 3.2B	cot	30	none	random	**76.36**
Qwen 2.5B	my_prompt	30	4bit	random	75.77
Qwen 2.5B	cot	30	none	random	75.36
Qwen 2.5B	cot	30	4bit	random	74.89
Llama 3.2B	cot	20	none	random	73.99
Qwen 2.5B	repeat_review	30	none	random	72.85

Taula 4: Millors resultats de few-shot prompting.

La millor configuració és Llama 3.2B amb el prompt *cot*, 30 shots i selecció aleatòria, amb una macro-F1 de 76.36. També hi ha resultats molt propers amb Qwen 2.5B, especialment amb 30

shots. Això indica que el nombre d'exemples és un factor important: les millors configuracions solen utilitzar 20 o 30 exemples.

En few-shot, a diferència de zero-shot el prompt de repetició sí que dona resultats competitius. La millor execució amb aquest prompt és Qwen 2.5B amb 30 shots i selecció *random*, arribant a 72.85 de macro-F1. No supera les millors execucions amb CoT, però queda clarament per sobre dels resultats de zero-shot. Això suggereix que la relectura interna és més útil quan el model també disposa d'exemples anotats al context.

El principal inconvenient de *diverse* i *coverage rerank*, que provoca que tot i tenir sentit teòricament no obtinguin resultats millors que *random*, és que prioritzen exemples amb molts sentiments diferents trobats.

Un dels problemes detectats al *zero-shot*, la detecció d'aspectes no presents al text, segurament es vegi incrementat per aquest tipus d'exemples més densos. Això podria explicar que aquestes estratègies no millorin la selecció aleatòria.

També és interessant que la quantització no sempre perjudica tant com en zero-shot. Per exemple, Qwen 2.5B amb *my_prompt*, 30 shots i 4bit arriba a 75.77. Això vol dir que, quan el model té exemples dins del context, part de la pèrdua causada per la quantització es pot compensar amb la informació addicional dels shots.

La taula 5 recull les comparacions aparellades principals:

Comparacio	Parelles	Base	Variant	Delta	Desv. delta
Qwen vs Llama	123	59.166	62.610	3.444	7.193
4bit vs no quant.	82	61.235	61.484	0.249	2.308
first vs random	56	63.968	61.325	-2.643	4.165
diverse vs random	76	65.828	55.063	-10.765	7.008
coverage rerank vs random	14	72.491	62.019	-10.472	6.011

Taula 5: Comparacions few-shot aparellades, controlant la resta de variables disponibles.

4.4 Conclusions

Clarament, els resultats de *few-shot* mostren que aquesta tècnica de *in-context learning* permet als models obtenir resultats significament millors que els del *zero-shot*.

En general, la tendència és que més shots ajuden al model. A més a més, en aquest cas, CoT també dona molt bons resultats, especialment quan es combina amb un nombre alt d'exemples. Tot i això, la millora no sembla venir només del prompt, sinó també de tenir 20 o 30 shots al context, i la diferència és menor que en zero-shot.
Respecte als models, en aquest cas sembla que Qwen és millor analitzant el seu context i transferint aquests exemples a prediccions més sòlides.

5 Data agumentation

Per realitzar data augmentation, la tasca s'inverteix: en lloc de generar setiquetes a partir d'un text, es proporciona al model amb unes combinacions de possibles aspectes i sentiments i se li demana que generi texts plausibles amb aquell resultat.

Addicionalment, el codi permet utilitzar el propi model per predir els aspectes d'aquella ressenya: si coincideixen, significa que segurament la generació sigui clara, mentre que si difereixen és probable que la ressenya tingui menys qualitat. Altre cop, degut al límit de recursos i per estalviar temps, no s'han filtrat les dades amb aquesta tècnica, però seria un punt d'anàlisi d'experiments futurs.

5.1 Variants de dades sintètiques

Es van considerar diverses variants. La primera era una generació general, amb el model Llama, seguint combinacions totalment aleatòries d'aspectes i polaritats. El nombre d'aspectes i la distribució venien donades per uns pesos per tal de que s'assemblés al dataset real.

Malgrat això, després d'analitzar els resultats de few-shot i de zero-shot, vam detectar que hi havia certs aspectes i polaritats que li costaven més al model. En part es deu a un des-balanceig de classes en el dataset d'entrenament. Per tant, vam decidir generar dades sintètiques donant més pes aquestes classes, centrant-nos en les que el model predia malament.

La tercera variant utilitza un model extern, amb moltes més capacitats i estat de l'art com és GPT-5.5. Amb aquest, partint del dataset original, es van generar 1000 noves mostres sintètiques.

5.2 Control manual de qualitat

Al generar dades sintètiques, i en general amb tots els datasets, és important assegurar-se que les dades siguin de qualitat. Per això, es va realitzar una inspecció manual d'alguns exemples generats abans d'executar els models.

Els aspectes avaluats manualment van ser: que la review fos natural i semblés escrita per un humà, que la polaritat indicada com a resposta correspongués realment al que posava la ressenya, que no s'afegissin categories que no responien a les dades originals i que totes les ressenyes fossin en anglès i castellà ja que aquest era el propòsit del problema.

Aquest procés va permetre detectar un problema en les primeres iteracions i és que tot i que la qualitat de les ressenyes era l'adequada, totes aquestes eren en anglès tant a les generades per Llama com per GPT.

Dataset	Ex.	en	es	altre	pos	neg	neu	conf
GPT synthetic 1000	1000	378	622	0	2710	869	154	126
Llama synthetic 1000 old	1000	0	0	1000	2279	798	188	262
Llama synthetic 1000 fixed	1000	325	675	0	2606	770	174	134
Weak aspects/polarities 600	600	300	300	0	522	523	526	517

Taula 6: Auditoria dels datasets sintetics generats. Les columnes de polaritat compten parelles aspecte-polaritat, no exemples.

6 Fine-tuning

El fine-tuning consisteix en entrenar el model amb les dades, i són els experiments on s'han obtingut els millors resultats. Alhora, realitzar finetuning suposa un cost més elevat tant de temps com de capacitat VRAM, i per tant s'ha utilitzat LoRA (o QLoRA) [2, 3]. Aquesta decisió és consistent amb la literatura recent, que mostra que LoRA aplicat correctament pot ser molt competitiu respecte al fine-tuning complet [5]. Inspirats pel blog, també hem comparat la performance d'aplicar LoRa només a l'*attention* o a totes les capes linears.

6.1 Datasets

Es van comparar diferents datasets. En primer lloc se n'utilitza un que només inclou les dades originals de train, cosa que serveix com a baseline per a la comparació amb els altres datasets. En segon lloc, tenim el conjunt que combina les dades reals amb les dades sintètiques generades artificialment amb els models.

També es van provar variants de dades sintètiques més focalitzades. En aquest cas, en lloc de generar exemples de manera uniforme, es van prioritzar combinacions d'aspectes i polaritats que apareixien poc al dataset original o que havien donat pitjors resultats en experiments previs.

6.2 LORA attention vs LORA all

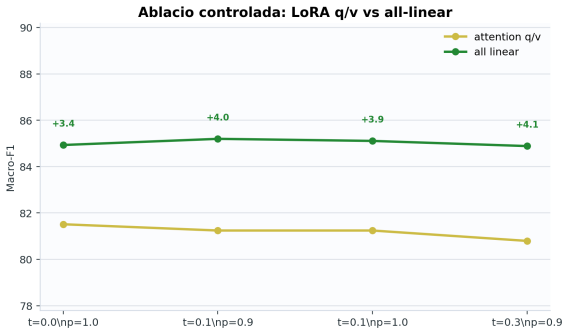


Figura 4: Ablacio controlada dels moduls LoRA en el millor regim Llama.

Sembla ser que aplicar LoRA a totes les capes linears del model, no només a q/v (attention), realment és beneficial per al model. Suposa lleugerament més recursos, però obté resultats significativament millors.

6.3 Resultats

El millor resultat de model individual és un fine-tuning de Llama 3.2 3B amb QLoRA 4bit, `bf16`, LoRA sobre totes les capes lineals, dades sintètiques focalitzades, `my_prompt`, temperatura 0.1 i *top-p* 0.9. Aquesta configuració obté 85.199 de macro-F1, 86.034 de micro-F1, 87.471 de macro-empty-F1, 100% de JSON vàlids i només 2.273% de prediccions buides.

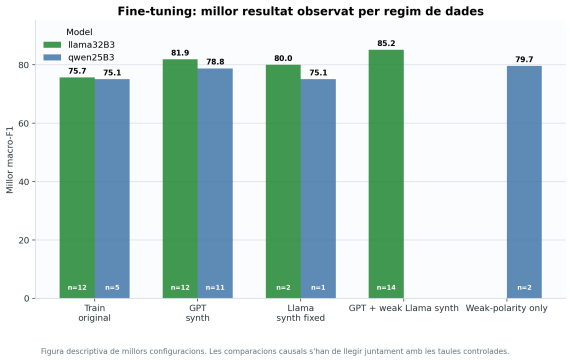


Figura 5: Millor resultat observat per regim de dades i model en fine-tuning.

Dades	Model	Quant.	Configuració	Macro-F1 mitjana	Millor macro-F1
Sintètic focalitzat	Llama	4bit	bf16, all linear	81.104	**85.199**
Sintètic GPT	Llama	4bit	my_prompt	77.276	81.918
Sintètic focalitzat	Llama	4bit	bf16, attention q/v	76.045	81.513
Sintètic GPT	Qwen	4bit	bf16, attention q/v	75.867	78.807
Train original	Qwen	4bit	bf16, attention q/v	72.480	75.079
Train original	Llama	4bit	configuració base	71.726	72.711

Taula 7: Principals grups de fine-tuning. La taula agrupa execucions similars.

Sobre el millor adaptador fine-tunejat, també vam realitzar una comparativa de hiperparàmetres. És interessant que, en aquest cas, el *greedy decoding* no és la millor opció.

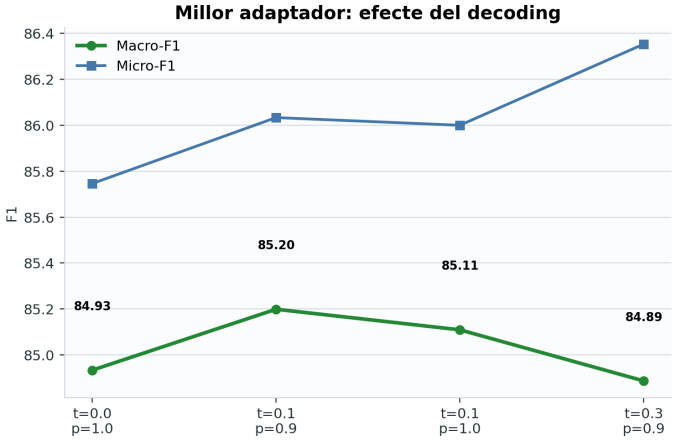


Figura 6: Sweep de decoding sobre el millor adaptador fine-tuned. La millor macro-F1 apareix amb temperatura 0.1 i top-p 0.9, tot i que greedy decoding queda molt a prop.

6.4 Conclusions

El finetuning proporciona el salt de rendiment més gran respecte a les famílies anteriors. A més, els factors estudiats que milloren més el rendiment són els mòduls LoRA (all-linear és millor que attention q/v, +3.4 a +4.1 punts) i l'ús de dades sintètiques focalitzades. En la comparació directa entre FP16 i BF16, o entre QLoRA i LoRA estàndard, sembla ser que els primers obtenen resultats lleugerament millors però fan falta més experiments per poder-ho demostrar.

7 Experiments addicionals

7.1 Ensembles

Per intentar acabar de refinar la sortida, es va intentar avaluar diferents "ensembles" de models, agafant els millors. La unió de diversos models, a diferència d'altres sistemes on s'utilitza un LLM per avaluar les diverses opcions, s'ha realitzat simplement amb les prediccions ja existent.

Amb aquesta tècnica, unint les prediccions de diferents models hem arribat a un validation f1 de 85.7. Tot i això, en la majoria de tècniques per unir-los, els resultats eren inferiors al millor model reportat.

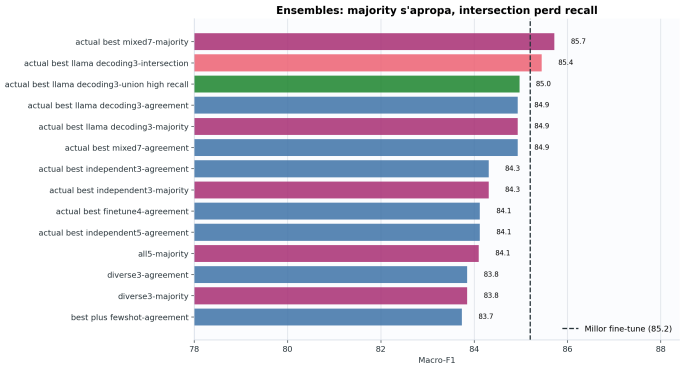


Figura 7: Comparacio dels millors ensembles. La línia discontinua marca el millor fine-tune individual; el millor ensemble el supera lleugerament.

7.2 Future work

En general, durant els experiments hem detectar diversos punts on seria interessant investigar en més profunditat, però en els que no hem pogut aprofundir degut als recursos. Per exemple, la comparativa entre l'entrenament a bf16 i fp16. Tant a few shot com a finetune, els models entrenats amb fp16 han reportat millors resultats que configuracions idèntiques en bf16. Això ens fa sospitar que el millor model podria acabar de millorar-se canviant aquesta precisió, així com afegint encara més dades sintètiques, entrenant més temps...

8 Conclusions generals

A partir dels experiments realitzats, s'ha obtingut una idea clara sobre el rendiment dels models de llenguatge en aquesta tasca de classificació de sentiments.

D'entrada, utilitzant una vista més global, els experiments mostren una clara evolució en el rendiment. Few-shot millora zero-shot, i finetunejar el model millora al seu torn aquest. Utilitzar ensembles permet acabar de rascar unes dècimes adicionals, en el nostre cas sense cost computacional, ja que les prediccions ja existien. D'aquí podem extreure que *prompting* sol no permet arribar al millor rendiment, però és una eina més i que LoRA és una tècnica que permet obtenir bons resultats amb un cost computacional menor a un entrenament complet.

Els casos més difícils, que fins i tot els millors models no solen resoldre, són aspectes i polaritats més aviats ambigües, on fins i tot un humà tindria problemes per diferenciar. A més, solen estar infra-representats en les dades disponibles.

El treball també mostra la importància de tenir unes bones dades, i , per exemple, seleccionar les classes menys representades per augmentar un dataset de forma més eficaç.

Les principals limitacions del treball són la manca de replicació multi-seed en alguns dels experiments. Tot i això, és un treball àmpli, que és capaç de detectar els efectes de diversos elements en el rendiment del model, amb diferents variants, controls... A més, també hem identificat algunes línies que semblen interessants explorar, com podria ser extendre el *test-time computing* utilitzant Reinforcement Learning (en lloc de CoT).

En conclusió, els experiments permeten mostrar quins factors permeten als LLMs millorar en la tasca de *Aspect Based Sentiment Analysis*, identificant quins son els motius principals i obtenint un model final amb un bon rendiment.

A Prompts utilitzats

Aquest annex recull els principals prompts utilitzats en els experiments de zero-shot, few-shot i inferència amb models fine-tuned. Les variables entre claus, com ara {`text`}, {`id`} i {`language`}, són substituïdes automàticament pel codi en temps d'inferència.

A.1 Prompt base (*my_prompt*)

Prompt base utilitzat com a plantilla principal en els experiments de zero-shot.

```
System:
You are an advanced Aspect-Based Sentiment Analysis (ABSA) system. Your task is to map
    specific aspects mentioned in restaurant reviews to their corresponding polarities.

### INSTRUCTIONS:
Read the instructions to understand the format and options. I will provide a new text for
    you to analyze. You MUST output a single, valid JSON object matching the format of
    the examples and absolutely nothing else. Return only the raw JSON without markdown
    blocks.

### CONSTRAINTS:
- ALLOWED ASPECTS: ‘restaurant_general‘, ‘restaurant_prices‘, ‘food_quality‘,
    ‘food_prices‘, ‘food_style_options‘, ‘drinks_quality‘, ‘drinks_prices‘,
    ‘drinks_style_options‘, ‘ambience‘, ‘service‘, ‘location‘.
- ALLOWED POLARITIES: ‘positive‘, ‘negative‘, ‘neutral‘, ‘conflict‘.
- Strict Omission: Do NOT include aspects that are not explicitly mentioned.

User:
Analyze the text and extract the aspects and polarities. Output a JSON object containing
    only the mapped keys and values.

### EXPECTED JSON SCHEMA:
{
  "<aspect_1>": "<polarity>",
  "<aspect_2>": "<polarity>"
}

### TEXT:
{text}
```

Listing 1: Prompt base utilitzat en zero-shot

A.2 Prompt de repetició (*repeat_review*)

Variant del prompt base amb una instrucció addicional de relectura interna abans de generar la sortida final.

```
System:
You are an advanced Aspect-Based Sentiment Analysis (ABSA) system. Your task is to map
    specific aspects mentioned in restaurant reviews to their corresponding polarities.

### INSTRUCTIONS:
```

```
Read the instructions to understand the format and options. I will provide a new text for
    you to analyze. You MUST output a single, valid JSON object matching the format of
    the examples and absolutely nothing else. Return only the raw JSON without markdown
    blocks.

### CONSTRAINTS:
- ALLOWED ASPECTS: ‘restaurant_general‘, ‘restaurant_prices‘, ‘food_quality‘,
    ‘food_prices‘, ‘food_style_options‘, ‘drinks_quality‘, ‘drinks_prices‘,
    ‘drinks_style_options‘, ‘ambience‘, ‘service‘, ‘location‘.
- ALLOWED POLARITIES: ‘positive‘, ‘negative‘, ‘neutral‘, ‘conflict‘.
- Strict Omission: Do NOT include aspects that are not explicitly mentioned.

Before predicting, reread the review by internally repeating/paraphrasing the full input
    text to yourself, then decide which explicit aspects and polarities are present.
This rereading step is only for reasoning. Do NOT output the repeated review,
    explanations, markdown, or any extra text.
The final answer must be only one valid JSON object with allowed aspect keys and allowed
    polarity values.

User:
Analyze the text and extract the aspects and polarities. Output a JSON object containing
    only the mapped keys and values.

### EXPECTED JSON SCHEMA:
{
  "<aspect_1>": "<polarity>",
  "<aspect_2>": "<polarity>"
}

### TEXT:
{text}

Before predicting, reread the review by internally repeating/paraphrasing the full input
    text to yourself, then decide which explicit aspects and polarities are present.
This rereading step is only for reasoning. Do NOT output the repeated review,
    explanations, markdown, or any extra text.
The final answer must be only one valid JSON object with allowed aspect keys and allowed
    polarity values.
```

Listing 2: Prompt de repetició de la review

A.3 Prompt Chain-of-Thought (*cot*)

Prompt amb metodologia pas a pas. La sortida esperada conté els camps `thought_process` i `opinions`.

```
System:
You are an advanced Aspect-Based Sentiment Analysis (ABSA) system.
You MUST output a single, valid JSON object and absolutely nothing else.
Do not use markdown code blocks around your output.
Return only the raw JSON.
```

```
User:
Analyze the review text using the step-by-step methodology below.

### METHODOLOGY:
Step 1. Read the review carefully to identify quotes related to the restaurant.
Step 2. Map those quotes strictly to the ALLOWED ASPECTS.
Step 3. Determine the sentiment of each mapped quote using only the ALLOWED POLARITIES.
Step 4. Output a JSON object. Use the "thought_process" key to briefly show your Step 1-3
    reasoning, then output the final extracted data in the "opinions" key.

### CONSTRAINTS:
- ALLOWED ASPECTS:
  - ‘restaurant_general‘
  - ‘restaurant_prices‘
  - ‘food_quality‘
  - ‘food_prices‘
  - ‘food_style_options‘
  - ‘drinks_quality‘
  - ‘drinks_prices‘
  - ‘drinks_style_options‘
  - ‘ambience‘
  - ‘service‘
  - ‘location‘
- ALLOWED POLARITIES:
  - ‘positive‘
  - ‘negative‘
  - ‘neutral‘
  - ‘conflict‘
- Strict Omission: Do NOT include aspects that are not explicitly mentioned.

### EXPECTED JSON SCHEMA:
{
  "thought_process": "<Briefly map quotes to aspects and polarities here>",
  "opinions": {
    "<aspect_1>": "<polarity>",
    "<aspect_2>": "<polarity>"
  }
}

### REVIEW TEXT:
<text>{text}</text>
```

Listing 3: Prompt Chain-of-Thought

A.4 Prompt amb definicions (*definitions*)

Prompt amb definicions explícites de les polaritats i dels aspectes.

```
System:
You are an expert Aspect-Based Sentiment Analysis (ABSA) system. Your task is to extract
    aspects and their sentiment polarities from restaurant reviews.
```

```
The reviews may be in English or Spanish, but you MUST strictly use the English aspect
    and polarity labels provided below.

### POLARITY DEFINITIONS:
- ‘positive‘: The aspect is evaluated positively.
- ‘negative‘: The aspect is evaluated negatively.
- ‘neutral‘: The aspect is evaluated with no strong feeling (e.g., "it is ok").
- ‘conflict‘: The aspect has BOTH positive and negative parts (e.g., "pizza was great,
    but meat was excessively cooked").

### ASPECT DEFINITIONS:
- ‘restaurant_general‘: General restaurant opinions.
- ‘restaurant_prices‘: Overall price of the restaurant.
- ‘food_quality‘: Taste and quality of the food.
- ‘food_prices‘: Cost of the food.
- ‘food_style_options‘: Presentation, originality, variety, portion size.
- ‘drinks_quality‘: Taste and quality of drinks.
- ‘drinks_prices‘: Cost of drinks.
- ‘drinks_style_options‘: Drink presentation, variety, portion.
- ‘ambience‘: Atmosphere, decor, vibe.
- ‘service‘: Staff kindness, promptness, attitude, professionalism.
- ‘location‘: Position, surroundings, view.

Return ONLY a valid, raw JSON object. No markdown code blocks.

User:
Analyze the review below. Extract only the aspects explicitly mentioned in the text and
    assign the correct polarity based on the definitions provided.

### EXPECTED JSON SCHEMA:
{
  "<aspect_1>": "<polarity_1>",
  "<aspect_2>": "<polarity_2>"
}

### REVIEW TEXT:
{text}
```

Listing 4: Prompt basat en definicions

A.5 Prompt amb regles de confusió (*confusion_guard*)

Prompt few-shot amb regles específiques per reduir confusions entre aspectes propers.

```
System:
You are a precise ABSA extractor for English and Spanish restaurant reviews.
You will see a few user/assistant examples before the target review.
Follow the examples' flat JSON format exactly.
Return exactly one valid flat JSON object and nothing else.

User:
Extract aspect polarities from the review.
```

```
Output format:
- A flat JSON dictionary only: {"aspect": "polarity"}
- Include only aspects with explicit evidence in the review.
- Use only these polarities: positive, negative, neutral, conflict.
- Use conflict only when the same aspect has both positive and negative evidence.
- If no aspect is explicitly evaluated, return {}.

Aspect rules:
- restaurant_general: overall recommendation, overall satisfaction, hype, "place",
    "sitio", "restaurante".
- restaurant_prices: overall restaurant price, bill, value, expensive/cheap when not tied
    to one item.
- food_quality: taste, cooking, freshness, delicious/bland/cold food.
- food_prices: price or value of dishes, menu, food portions for the money.
- food_style_options: variety, menu options, presentation, originality, portion size.
- drinks_quality: taste or quality of wine, cocktails, beer, coffee, drinks.
- drinks_prices: price or value of drinks.
- drinks_style_options: drink variety, presentation, sizes, options.
- ambience: atmosphere, decoration, comfort, noise, music, cleanliness, crowding.
- service: staff, waiters, friendliness, speed, waiting, reservations, professionalism.
- location: centrality, neighborhood, surroundings, access, views.

Frequent mistakes to avoid:
- Generic praise is restaurant_general, not food_quality, unless food is named.
- Central, near, neighborhood, and views are location, not ambience.
- Decoration, noise, comfort, and vibe are ambience, not location.
- Dish/menu price is food_prices; overall bill/value is restaurant_prices.
- Mention service only when staff, waiting, attention, reservation, or speed is evaluated.

Review id: {id}
Language: {language}
Review:
{text}
```

Listing 5: Prompt few-shot amb regles de desambiguació

A.6 Anàlisi d'errors

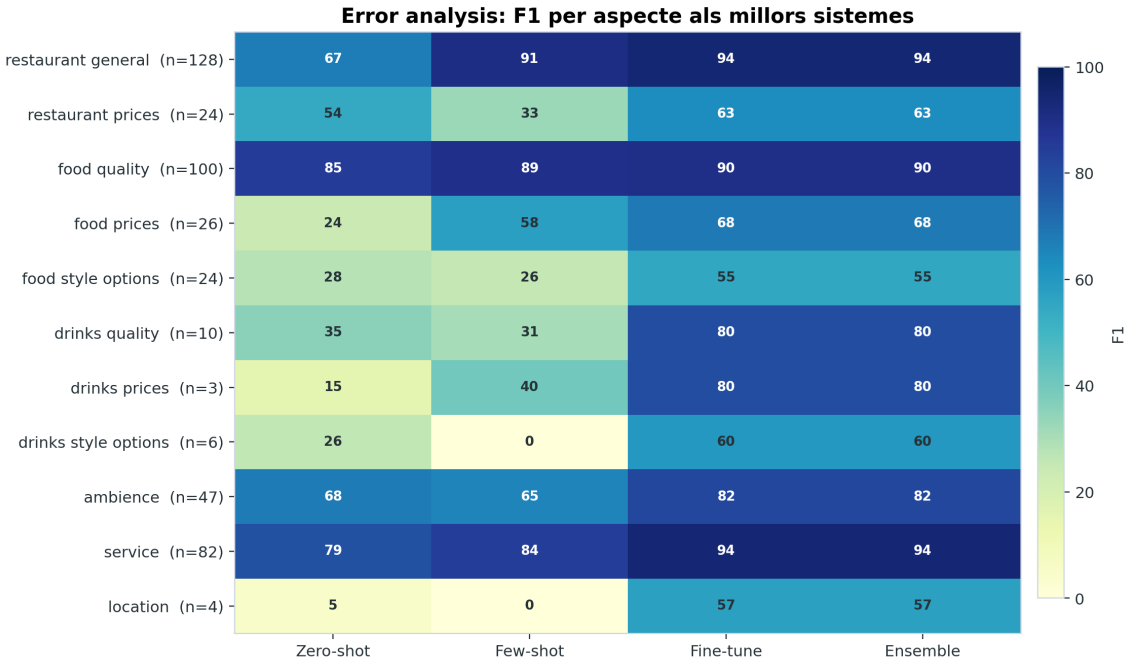


Figura 8: F1 per aspecte als millors sistemes de cada família. Els valors mostren que el fine-tuning millora sobretot classes minoritaries com `drinks_quality`, `drinks_prices` i `location`, encara que algunes continuen sent difícils.

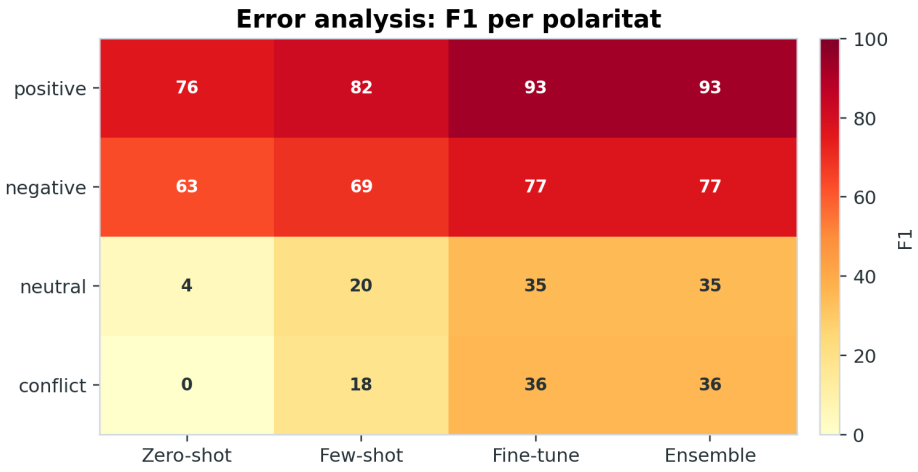


Figura 9: F1 per polaritat als millors sistemes. Les polaritats `neutral` i `conflict` continuen sent les mes difícils, tot i millorar clarament amb fine-tuning i ensemble.

A.7 Material addicional d'experiments

Familia	Runs uniques	Millor macro-F1	Micro-F1
Zero-shot	104	63.438	61.139
Few-shot	292	76.358	76.307
Fine-tuning	61	85.199	86.034
Ensemble	47	85.718	87.273

Taula 8: Millor resultat obtingut per cada familia experimental. Les files estan deduplicades per run_id.

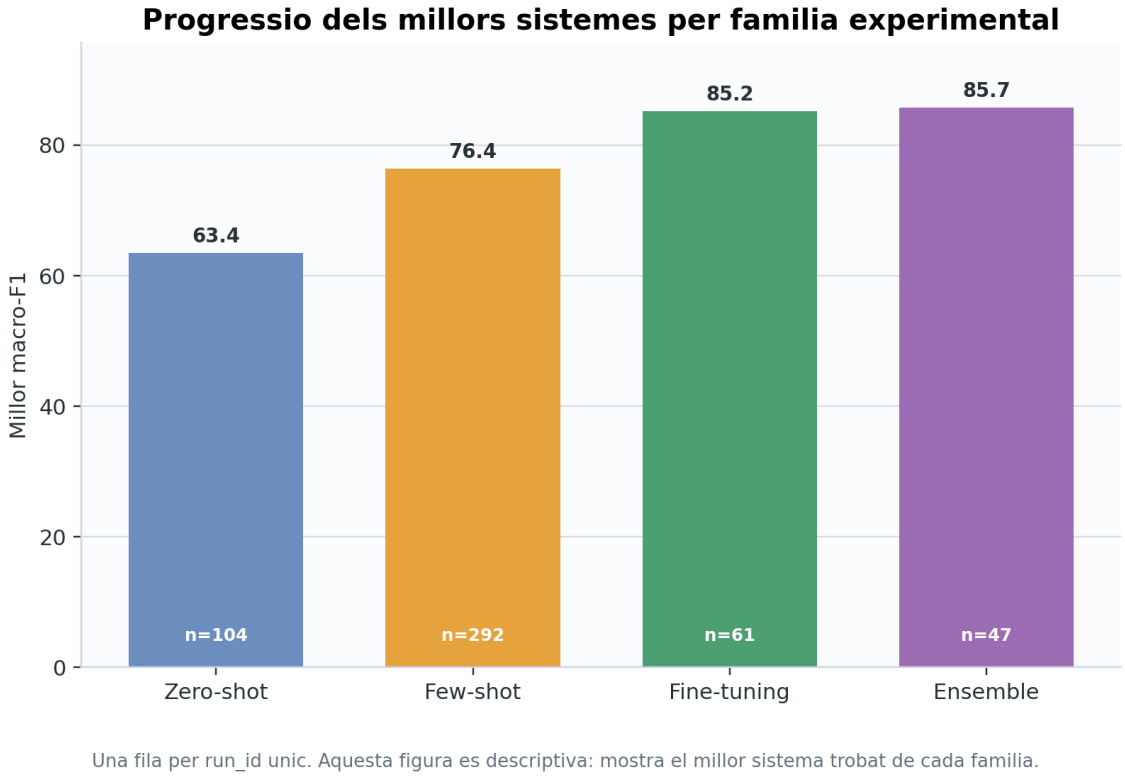


Figura 10: Millor macro-F1 per familia experimental. Es una vista compacta de la progressio zero-shot, few-shot, fine-tuning i ensemble.

Temp.	Top-p	LoRA q/v	LoRA all-linear	Δ
0.0	1.0	81.513	84.933	+3.420
0.1	0.9	81.243	85.199	+3.956
0.1	1.0	81.243	85.109	+3.866
0.3	0.9	80.795	84.887	+4.092

Taula 9: Efecte controlat dels mòduls LoRA en Llama amb dades sintètiques focalitzades.

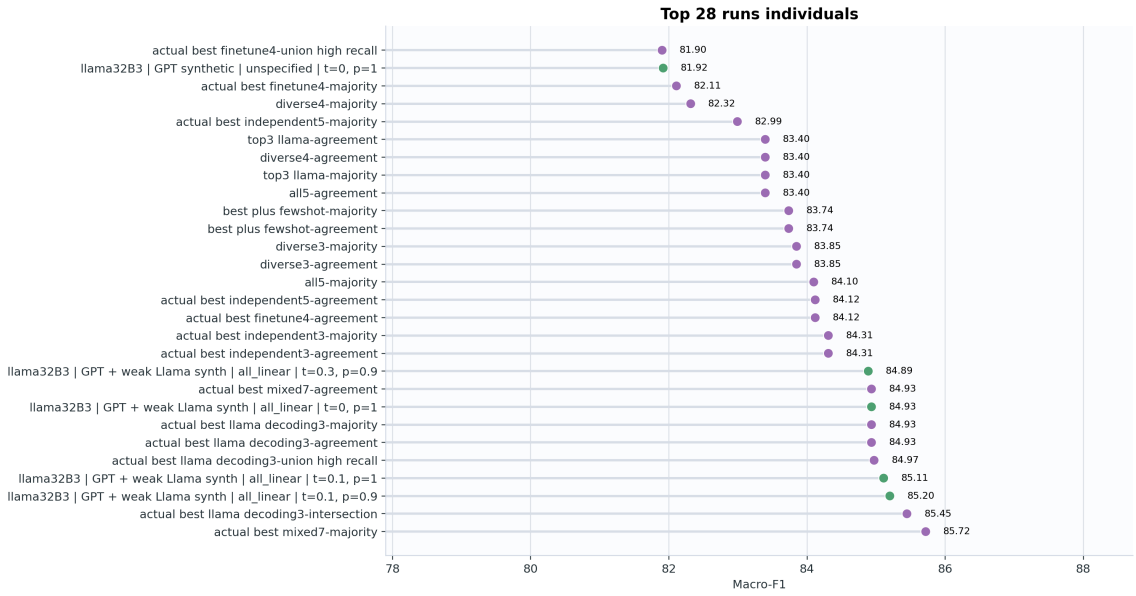


Figura 11: Top d'execucions individuals. Aquesta figura es densa i funciona millor com a material d'annex que com a figura principal.

Membre	Familia	Macro-F1
Llama weak all-linear, t=0.1 p=0.9	Fine-tune	85.199
Llama weak all-linear, t=0.1 p=1.0	Fine-tune	85.109
Llama weak all-linear, greedy	Fine-tune	84.933
Llama GPT synthetic, 10 epochs	Fine-tune	81.918
Qwen weak-polarity all-linear	Fine-tune	79.687
Qwen GPT synthetic QLoRA	Fine-tune	78.807
Llama few-shot CoT 30 random	Few-shot	76.358

Taula 10: Membres del millor ensemble, actual_best_mixed7-majority.

Familia	Model	Prompt	Macro-F1	Micro-F1	Run
Ensemble	ensemble	ensemble	85.718	87.273	actual_best_mixed7-majority-repairnone
Ensemble	ensemble	ensemble	85.446	86.486	actual_best_llama_decoding3-intersection_high_precision-repa
Fine-tuning	llama32B3	my_prompt	85.199	86.034	final_finetune_decoding_final_finetune_llama_weak_polarity_sy
Fine-tuning	llama32B3	my_prompt	85.109	86.000	final_finetune_decoding_final_finetune_llama_weak_polarity_sy
Ensemble	ensemble	ensemble	84.971	85.619	actual_best_llama_decoding3-union_high_recall-repairnone
Ensemble	ensemble	ensemble	84.933	85.746	actual_best_llama_decoding3-agreement_then_tiebreak-repairn
Ensemble	ensemble	ensemble	84.933	85.746	actual_best_llama_decoding3-majority-repairnone
Fine-tuning	llama32B3	my_prompt	84.933	85.746	final_eval_existing_adapter_final_finetune_llama_weak_polarity
Ensemble	ensemble	ensemble	84.933	85.746	actual_best_mixed7-agreement_then_tiebreak-repairnone
Fine-tuning	llama32B3	my_prompt	84.887	86.353	final_finetune_decoding_final_finetune_llama_weak_polarity_sy
Ensemble	ensemble	ensemble	84.309	85.386	actual_best_independent3-agreement_then_tiebreak-repairnon
Ensemble	ensemble	ensemble	84.309	85.386	actual_best_independent3-majority-repairnone

Taula 11: Top 12 runs individuals deduplicats per $\text{run}_i d$.

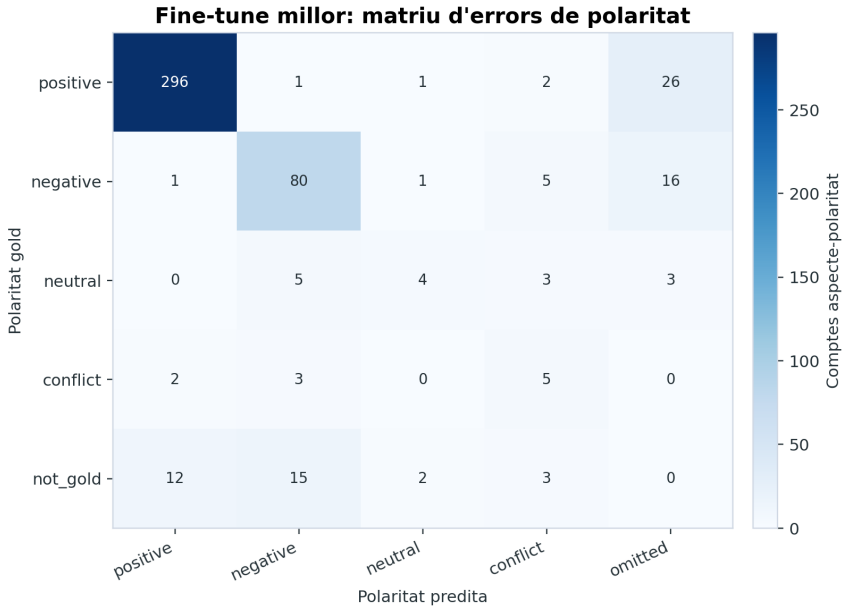


Figura 12: Matriu de confusio de polaritats per al millor fine-tune individual.

Llengua	Zero-shot	Few-shot	Fine-tune	Ensemble
en	62.944	71.515	83.537	84.923
es	59.967	79.086	87.478	88.649

Taula 12: F1 per llengua dels millors sistemes de cada familia.

Camp	Valor
Best eval run	llama_weak_polarity_synth-finetune-my_prompt-q4bit-loraall_linear-t0.1-p0.9-seed13
Macro-F1	85.199
Micro-F1	86.034
Data regime label	GPT + weak Llama synth
Base train data	artifacts/generated_data/gpt5.5_1000/train_plus_synth.json
Additional synthetic data	generated_data/synthetic_weak_aspects_600-llama32B3-t0.8-p0.95.json
Model	llama32B3
Quantization	4bit
Precision	bf16
LoRA target	all_linear
Epochs	5.0
Learning rate	2e-05

Taula 13: Proveniencia del millor fine-tune. El millor model combina GPT synthetic amb dades weak-aspect generades amb Llama.

Referències

[1] J. Wei, X. Wang, D. Schuurmans, M. Bosma, B. Ichter, F. Xia, E. Chi, Q. Le, and D. Zhou, "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models," *arXiv preprint arXiv:2201.11903*, 2022. [Online]. Available: https://arxiv.org/abs/2201.11903

[2] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "LoRA: Low-Rank Adaptation of Large Language Models," *arXiv preprint arXiv:2106.09685*, 2021. [Online]. Available: https://arxiv.org/abs/2106.09685

[3] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer, "QLoRA: Efficient Finetuning of Quantized LLMs," *arXiv preprint arXiv:2305.14314*, 2023. [Online]. Available: https://arxiv.org/abs/2305.14314

[4] Y. Leviathan, M. Kalman, and Y. Matias, "Prompt Repetition Improves Non-Reasoning LLMs," *arXiv preprint arXiv:2512.14982*, 2025. [Online]. Available: https://arxiv.org/abs/2512.14982

[5] J. Schulman, "LoRA Without Regret," *Thinking Machines Lab*, 2025. [Online]. Available: https://thinkingmachines.ai/blog/lora/